

一、核心问题总结

1. 智能体出现奖励作弊 (Reward Hacking) , 高分但任务失败

- 原始奖励规则仅对单次拾取动作成功给予固定正向奖励, 无防重复抓取惩罚:
- 智能体发现漏洞: 停在目标物体旁反复执行 PickupObject, 持续刷取拾取奖励, 累计回报虚高 (如 Episode45 达 9.98) ;
- 完全放弃真实任务: 不愿移动、搬运物体归位, 原地刷分直至步数上限超时, 所有物体均复原失败。

2. 奖励机制设计缺陷 (稀疏奖励, 无分阶段引导)

- 无阶段区分: 空手、手持物体两种状态共用同一套距离惩罚, 智能体分不清“先捡物体”“再送回原位”两步流程;
- 缺少过程密集奖励: 仅最终归位有收益, 中途导航无正向激励, 智能体容易直接冲向目标空位, 忽略拾取错乱物体;
- 无效动作无惩罚: 手持物体时重复抓取、无意义放置动作不会扣分, 纵容投机行为。

二、奖励机制重构 (核心: 分阶段密集奖励 + 封堵作弊漏洞)

1. 封堵重复抓取刷分漏洞

- 空手执行 PickupObject 且抓取成功: 一次性高额正向奖励 (5 分) ;
- 已持有物体仍调用抓取动作: 禁止执行抓取, 替换为空操作并施加负惩罚, 杜绝无限刷分。
- 无物体可放置时调用 PutObject: 同样施加负惩罚, 约束无效动作。

2. 两阶段分层距离引导奖励 (Dense Reward Shaping)

- 空手阶段: 距离惩罚绑定错乱物体当前位置, 引导智能体先靠近、拾取物体;
- 持物阶段: 距离惩罚切换至原始记忆目标点位, 引导携带物体返回初始位置;
- 增加全局微小时间惩罚: 每步轻微扣分, 避免智能体原地磨蹭、延长路径。

- 强化最终完成收益：物体放置到原始坐标误差 ≤ 0.15 米时，给予大额完成奖励（20 分），标记任务完成 `done=True`，强化“成功归位”的目标导向。